Ch2 Transformer Anatomy: Residual Stream & Attention Head

Source: reading_pack/md/A02_Transformer.md | Full textbook: TEXTBOOK_Stability_Identifiability.md

■2■ Transformer ■■■Residual Stream ■ Attention Head

2.1 ■■■■■

```
r■ = Embed(tokens)
for ■=1..L:
  o_{■,h} = Attn_{■,h}(r_{■-1})  ∈ ■^d      // ■■ head ■■■
  o_■ = concat_h o_{■,h} ∈ ■^{D·H}
  r_{■} = r_{■-1} + W_■·o_■ + MLP(...)    // Residual Stream ■■
r_L → Unembed → logits
```

• `r_■` ■ **Residual Stream**■■■ head+MLP ■■■■■■■ MVP ■■■■■■`features[:,■,:]`■■

• `x_{■,h}=o_{■,h}` ■ **Attention Head ■■**■Kim ■■■■■1024■■■■■

■■■■■■■■■ `r_■` ■■■■■■■■■■■■■■■■■■`x_{■,h}` ■■■■■middle layer ■■■■■Kim Fig.2■■■■ `best layer 24` vs Kim `layer 16` ■■■ **■■■ vs ■■** ■■■■

■■■■■ *Elhage p.12-14 Fig.1■Kim Sec.2 ■■(1)-(3) p.2-4*

2.2 ■■■

• **Elhage Fig.1■** ■■ residual ■■■■■ head ■■■■■ `W_{■,h}` ■ `D×d` ■■■■`W_■ = [W_{■,1}...W_{■,H}]`■
